

1. Постоянное кол-во параметров и размер выходов

#	Слой	Вход	Выход	Параметры
1	Conv 7x7, s=2	$3 \cdot S \cdot S$	$32 \cdot S_{12} \cdot S_{12} = 8 S^2$	$3 \cdot 32 \cdot 7^2 = 4704$
2	ReLU	$8 S^2$	$8 S^2 (32 \cdot S_{12} \cdot S_{12})$	-
3	MaxPool 3x3, s=2, p=1	$8 S^2 (32 \cdot S_{12} \cdot S_{12})$	$8 S_{14}^2 = 2 S^2 (32 \cdot (\frac{S}{4})^2)$	-
4	Conv 5x5	$2 S^2 (32 \cdot (\frac{S}{4})^2)$	$2 S^2 \cdot 2 = 4 S^2 (64 \cdot (\frac{S}{4})^2)$	$32 \cdot 64 \cdot 5^2 = 51200$
5	Conv 3x3, s=2	$4 S^2 (64 \cdot (\frac{S}{4})^2)$	$4 S^2 \cdot \frac{1}{4} = 2 S^2 (128 \cdot (\frac{S}{8})^2)$	$64 \cdot 128 \cdot 3^2 = 73728$
6	Conv 1x1	$2 S^2 (128 \cdot (\frac{S}{8})^2)$	$2 S^2 \cdot 2 = 4 S^2 (256 \cdot (\frac{S}{8})^2)$	$128 \cdot 256 = 32768$
7	Conv 3x3, s=2	$4 S^2 (256 \cdot (\frac{S}{8})^2)$	$4 S_{14}^2 = S^2 (256 \cdot (\frac{S}{16})^2)$	$256 \cdot 256 \cdot 3^2 = 589824$
8	Conv 1x1	$S^2 (256 \cdot (\frac{S}{16})^2)$	$S^2 \cdot 2 = 2 S^2 (512 \cdot (\frac{S}{16})^2)$	$256 \cdot 512 = 131072$
9	Global AvgPool	$2 S^2 (512 \cdot (\frac{S}{16})^2)$	512	-
10	ReLU Linear	512	256	$512 \cdot 256 + 256 = 131328$
11	ReLU	256	256	-
12	Linear	256	100	$256 \cdot 100 + 100 = 25700$

Итого 1040324 параметров, FP32 весы 48 → 6 байт $Q = 41612968$

2. Расчет FLOPs

Для сверток нужно $F = 2 \cdot \text{Выход} \cdot \text{Размер(канал)входа} \cdot \text{Размерность}^2$

Для линейного слоя нужно $F = 2 \times \text{Вход} \times \text{Выход}$

Тогда для всех сверток нужно $(2 \cdot 8 \cdot 3 \cdot 49 S^2) + (2 \cdot 4 S^2 \cdot 32 \cdot 25) + (2 \cdot 2 S^2 \cdot 64 \cdot 9) +$
 $+ (2 \cdot 4 S^2 \cdot 128) + (2 \cdot S^2 \cdot 256 \cdot 9) + (2 \cdot 2 S^2 \cdot 256) = 17712 S^2$

Для линейных $(2 \cdot 512 \cdot 256) + (2 \cdot 256 \cdot 100) = 313344$

Значит $\boxed{FLOPs(S, B) = B(17712 S^2 + 313344)}$

3. Пиковая память

Т.к. в режиме eval() и inference mode() нет backpropagation.

Значит каждый момент времени входной и выходной тензор + веса

Тогда максимум будет для первого слоя $3 S^2 + 8 S^2 = 11 S^2$

Для байта B это значит $11BS^2$, при FP32. $44BS^2, 4$
с учетом весов $\boxed{\text{Max Memory}(S, B) = 44BS^2 + 4161296}$

4. Перемещение матрицы за 1 проход

Для обычного оператора график = $4 \cdot (Вход + Выход) \cdot B + \text{веса параметров}$

Для RELU с in-place делается только чтение и запись $\rightarrow$ график аналогичен оператору без весов параметров. Для всех слоев (до 1000) суммарно $4 \cdot 91S^2B = 364BS^2$. У 1000 слоев 8592B, значит за 1 полный проход

$$\boxed{Q(S, B) = 364BS^2 + 8592B + 4161296}$$

5. Latency

В roof-line модели каждый оператор ограничен либо вычислением, либо памятью, тогда $\text{Latency}_i = \max\left(\frac{F_i(S, B)}{F_{\text{eff}}}, \frac{Q_i(S, B)}{BW_{\text{eff}}}\right)$, где

F_{eff} - эффективная пропускная GPU, BW_{eff} - эффективная bandwidth.
 F_i/F_{eff} - вычисл. время, Q_i/BW_{eff} - время передачи данных. Учитывая, что есть время запуска CUDA ядер c , итоговое

$$\boxed{\text{Latency}(S, B, \Theta) = c + \sum_c \max\left(\frac{F_i(S, B)}{F_{\text{eff}}}, \frac{Q_i(S, B)}{BW_{\text{eff}}}\right)}, \text{ где } \Theta = \{F_{\text{eff}}, BW_{\text{eff}}, c\}$$

6. Энергия

Для одного прохода число потраченной энергии

$$\boxed{E(S, B, \Theta) = e_{\text{flop}} \cdot \text{FLOPs}(S, B) + e_{\text{byte}} \cdot Q(S, B) + E_0}, \text{ где } \Theta = \{E_0, e_{\text{flop}}, e_{\text{byte}}\}$$

e_{flop} - затраты на 1 FLOP, e_{byte} - затраты на передачу байта,

E_0 - постоянная энергия запуска, прочие...