

Super-Convergence

Как обучить нейросеть на порядок быстрее, если не бояться
большого learning rate

Разбор и воспроизведение статьи

L. N. Smith, N. Topin, arXiv:1708.07120

Даниил Иванов

Стандартное обучение — это долго

80 000

итераций нужно ResNet-56 на CIFAR-10,
чтобы дойти до 91.2% точности

При batch 1 000 это 1 600 эпох

Типичный режим

Глобальный LR ≈ 0.1 , держим его, пока точность не выйдет на плато, затем делим на 10. Повторяем 2–3 раза.

Вопрос статьи

Можно ли учить с LR на порядок больше — и сойтись в разы быстрее, не потеряв точность?

В 8 раз меньше итераций — и точность выше

92.4%

1cycle, LR от 0.1 до 3

10 000 итераций

91.2%

Ступенчатый LR, старт 0.35

≈ 80 000 итераций


×8

меньше итераций

92.1% уже за 6 000

Это явление авторы назвали **super-convergence**: сеть сходится на порядок быстрее и к лучшему решению.

Тест диапазона LR: где можно ускориться



По горизонтали — LR, растёт линейно; по вертикали — точность на тесте

— **ResNet-56** плато до LR = 3 (рис. 2b)

— **Типичная сеть** пик, затем спад (рис. 2a)

Как устроен

Короткое обучение, в котором LR линейно растёт от нуля. Смотрим, при каком LR сеть ещё учится.


Обычный случай

Точность достигает пика и падает. LR на пике — верхняя граница для циклического LR.

Признак **super-convergence**

Пика нет: точность высокая вплоть до LR = 3 — на порядок больше обычного.

Политика 1cycle: один цикл LR



Рост: 0.1 → 3

Старт с малым шагом, затем разгон. Половина цикла.

Спад: 3 → 0.1

Огромный шаг даёт шум: сеть быстро проходит пологую «долину» функции потерь.

Отжиг

LR на порядки ниже: оседаем в минимум.

Цикл короче бюджета — на последние итерации LR опускается намного ниже стартового. Momentum можно менять в противофазе к LR.

Большой LR работает как регуляризатор



Разрыв train/test сокращается

При росте LR от 0.2 до 2 train loss растёт, а test loss падает — классический признак регуляризации (рис. 8а).



Регуляризацию надо балансировать

Большой LR уже добавляет шум, поэтому weight decay, dropout и малый batch стоит ослабить.



BatchNorm с короткой памятью

MAF 0.999 не успевает за быстро меняющимися весами — в коротком обучении нужно 0.85–0.95.

Оптимальный LR без гессиана

$$\varepsilon^* = \varepsilon \cdot \frac{\sum |\theta(t+1) - \theta(t)|}{\sum |2\theta(t+1) - \theta(t) - \theta(t+2)|} \quad (\text{ур. 8})$$

Откуда

Метод Ньютона по направлению спуска: кривизну оцениваем конечной разностью градиентов, а градиенты выражаем через три соседних вектора весов. Суммы по всем весам дают один глобальный LR, сглаженный EMA с $\alpha = 0.1$.

Что показывает

Для ResNet-56 оценка 2–6 — большие LR оправданы. При 1cycle она остаётся высокой (≈ 0.5 к концу), при постоянном LR падает к ≈ 0.2 : малая кривизна, плоские широкие минимумы.

Выигрыш тем больше, чем меньше данных

Эксперимент (CIFAR-10)	Ступенчатый	1cycle	Разница
ResNet-56, 10 000 обучающих примеров	71.4%	80.6%	+9.2 п.п.
ResNet-56, 20 000 обучающих примеров	82.7%	87.9%	+5.2 п.п.
ResNet-56, все 50 000 примеров	91.2%	92.4%	+1.2 п.п.
ResNet-20	88.6%	90.4%	+1.8 п.п.
ResNet-110	91.0%	92.1%	+1.1 п.п.
ResNet-56 с Nesterov momentum	90.9%	92.1%	+1.2 п.п.

Ступенчатый режим — 80 000 итераций, 1cycle — 10 000. С Adam авторам super-convergence получить не удалось.


Повторяем на одном бесплатном GPU

Параметр	Статья	Наше воспроизведение
Железо и код	8× Titan Black, Caffe	1× Tesla T4 (Colab), PyTorch
Сеть и данные	ResNet-56 (табл. 3–5), CIFAR-10	то же
Batch	1 000	1 000
1cycle	LR 0.1–3, 4 000 итераций → 91.1%	LR 0.1–3, 4 000 итераций
Ступенчатый LR	старт 0.35, ≈ 80 000 итераций	старт 0.35, 4 000 и 12 000 итераций
SGD	momentum 0.9, WD 1e-4, форма Caffe	то же: $v \leftarrow \mu v + lr \cdot g$
Точность чисел	fp32	fp16 + GradScaler

Строка табл. 6 «4 000 итераций, BN MAF 0.85» повторена один в один — её можно сравнить напрямую.

1cycle: 91.9% за 4 000 итераций

1cycle против ступенчатого LR: ResNet-56, CIFAR-10, batch 1 000



91.9%

наш 1cycle

91.1%


в статье, табл. 6

84.7%

ступенчатый LR за те же 4 000

Плато до LR = 3 — как на рис. 2b

Тест диапазона LR: ResNet-56, CIFAR-10, LR от 0 до 3 за 2 000 итераций



0.92

удержание: точность при LR ≥ 2.5 /
пик


69%

плато при LR ≥ 0.5 ; в статье $\approx 65\text{--}80\%$

У типичной сети с пиком и спадом удержание ≈ 0.45 (рис. 2a). Скачки точки к точке — шум снимков весов при огромном LR, поэтому пик ищем по скользящей медиане.

Оценка LR по ур. 8 на наших прогонах

Оценка оптимального LR упрощённым Hessian-free (ур. 8)



2.6

медиана 2-й половины, 1cycle

0.075

ступенчатый LR, 4 000 итераций

Качественно как рис. 3b. Оценка пропорциональна текущему LR, поэтому на хвосте 1cycle она тоже падает.

Чем наше воспроизведение отличается

Короче стандартный режим

12 000 итераций вместо 80 000: 1 600 эпох на T4 — больше суток. Проверяем слабую форму: 1cycle не хуже режима с бюджетом в 3 раза больше.

Один seed

Разброс между запусками не оценивали. Разницы меньше ~0.5 п.п. считаем незначимыми.

fp16 и stride 1

Смешанная точность ради скорости. Первая свёртка со stride 1: stride 2 из табл. 5 не сходится с avg-pool 8×8.

Наши допущения

Моменты снижения LR (50% и 75% бюджета) и хвост 1cycle (10% бюджета) статья не задаёт.